LAPORAN MINI PROYEK C

REKAYASA DATA



Anggota Kelompok B (Kelas A) :

Winata Cang Vielon	6162301007
Maria Chelsea Olivia	6162301009
Marco Dharmaputra	6162301041
Febriana Austin Darmawan	6162301069
Bryant Andrew Kristiali	6162301073

Dosen:
Robby, M.Si

PROGRAM STUDI MATEMATIKA
FAKULTAS SAINS
UNIVERSITAS KATOLIK PARAHYANGAN
2026

Daftar Isi

Daftar Isi **2**

Daftar Tabel **2**

Daftar Gambar **2**

1 Latar Belakang **3**

2 Identifikasi Masalah **3**

3 Tujuan **3**

4 Pembersihan Data **3**

5 Perbaikan ERD **5**

6 Hasil Pengolahan Data **6**

7 Data Sintesis **8**

8 Kesimpulan **8**

Daftar Tabel

Tabel

1 Daftar Lagu 4
2 Data Tabel music_users 4
3 Log Aktivitas Mendengarkan Lagu 5
4 Tabel Total Pemutaran Berdasarkan *genre_text* 6
5 Tabel Total Pemutaran Berdasarkan *artist_text* 6
6 Tabel Total Pemutaran Berdasarkan *username* 7
7 Log Aktivitas Mendengarkan Lagu 8
8 Data Sintetis Tambahan 8

Daftar Gambar

Gambar

1 Diagram E-R 6
2 Grafik Garis Distribusi Waktu 7

1 Latar Belakang

Basis data yang digunakan dalam studi ini merupakan data operasional dari *platform streaming* musik yang digunakan untuk mencatat aktivitas pengguna dalam memutar lagu. Data ini belum dirancang untuk kebutuhan analisis sehingga masih terdapat berbagai penulisan data yang belum konsisten.

Tujuan dari laporan ini adalah untuk mestandarisasi data agar dapat digunakan untuk analisis lebih lanjut, serta menjawab beberapa pertanyaan terkait perilaku pengguna dan popularitas musik.

2 Identifikasi Masalah

Berdasarkan eksplorasi awal, ditemukan beberapa permasalahan dalam basis data sebagai berikut

1. Penulisan genre yang tidak konsisten (misalnya, “pop indonesia”, “pop-ID”, “indie-pop”)
2. Jenis event pemutaran yang tidak seragam
3. Format waktu pemutaran masih dalam bentuk string dengan format yang berbeda-beda
4. Relasi antar tabel belum menggunakan foreign key yang jelas
5. Potensi inkonsistensi data seperti durasi pemutaran yang tidak wajar

3 Tujuan

Untuk mengatasi permasalahan tersebut, dilakukan beberapa tahap pembersihan data, yaitu

1. Penulisan genre dinormalisasi sehingga berbagai variasi dapat dikelompokkan menjadi kategori utama seperti pop, *rock*, *electronic*, dan *acoustic*.
2. Jenis aktivitas seperti “Play”, “playing”, dan variasi lainnya diseragamkan menjadi kategori standar seperti play, pause, dan skip.
3. Atribut waktu yang sebelumnya berupa string dengan format yang berbeda (YYYY-MM-DD, YYYY/MM/DD, dan DD/MM/YYYY) dikonversi menjadi tipe data DATETIME.
4. Relasi antar tabel dibangun kembali melalui proses join antara tabel users, songs, dan listening_logs sehingga terbentuk struktur data yang lebih konsisten.
5. Data yang tidak wajar seperti durasi terlalu pendek atau terlalu panjang diidentifikasi sebagai potensi anomali.

4 Pembersihan Data

Secara umum, proses pengambilan keputusan berdasarkan suatu basis data (*database*) dapat dilakukan secara maksimal apabila *database* yang digunakan sudah fungsional. Dengan demikian, langkah awal yang baik adalah dengan membersihkan data atau *data cleaning*. Terdapat lima langkah utama, yaitu

1. Kategorisasi Genre
   Perhatikan tabel music_songs berikut ini.

Tabel 1: Daftar Lagu

song_id	**title**	**artist_name**	**genre_text**
1	Langit Senja	Adera	Pop
2	Rindu Malam	Arsy	pop indonesia
3	City Lights	Nova	POP-ID
4	Broken Roads	The Waves	Alt Rock
5	Silent Echo	The Waves	alternative-rock
6	Midnight Drive	Aurora	Rock Alternatif
7	Summer Rain	Luma	Indie Pop
8	Ocean Blue	Luma	indie-pop
9	Heartbeat	Neon	Electronic
10	Pulse	Neon	EDM
11	Morning Coffee	Acoustic Duo	Acoustic
12	Slow Sunday	Acoustic Duo	acoustic folk

Terdapat ketidakkonsistenan pada kolom genre_text yang mana ada yang ditulis menggunakan huruf kapital serta penggunaan tanda (-), ada yang tidak, sehingga seluruh isi kolom genre_text diperbaiki dan ditulis kembali tanpa menggunakan huruf kapital dan tanpa tanda (-). Kemudian, isi dari kolom tersebut dikategorikan menjadi 5 kategori genre, yaitu

- Seluruh genre yang mengandung kata 'pop' akan dikategorikan sebagai genre **pop**;
- Seluruh genre yang mengandung kata 'rock' akan dikategorikan sebagai genre **rock**;
- Genre EDM dan electronic dikategorikan sebagai genre **electronic**;
- Genre acoustic dan acoustic folk dikategorikan sebagai genre **acoustic**;
- Genre-genre selain daripada itu dikategorikan sebagai **other**.

Selain genre, perlu dilakukan kategorisasi pada dataset *music_users* kolom country. Perhatikan tabel music_users berikut:

Tabel 2: Data Tabel music_users

user_id	**username**	**country**
1	andi_music	id
2	budi88	Indonesia
3	citra.id	SG
4	dewii	MY
5	eko_stream	ID
6	farah23	SG
7	gilangplay	ID
8	hana_l	id
9	indra99	id
10	joko_live	Indonesia
11	kiki_song	SG
12	linaaudio	Indonesia
13	mira_beats	Indonesia
14	nando_vibes	Indonesia
15	oki_listen	MY

Terdapat ketidakkonsistenan pada kolom country, dimana negara Indonesia ditulis dengan beberapa penulisan yang tidak konsisten. Oleh karena itu, akan dikategorikan menjadi 3 kategori country, yaitu

- Seluruh country yang mengandung makna Indonesia seperti 'ID' dan 'Indonesia' akan dikategorikan sebagai country **ID**;
- Seluruh country yang mengandung makna Malaysia seperti 'MY' akan dikategorikan sebagai country **MY**;
- Seluruh country yang mengandung makna Singapore seperti 'SG' akan dikategorikan sebagai country **SG**.

2. Normalisasi Event
   Perhatikan tabel music_listening_logs berikut ini.

Tabel 3: Log Aktivitas Mendengarkan Lagu

log_id	**user_name**	**song_title**	**event_type**	**listen_timestamp**	**duration_seconds**
1	kiki_song	City Lights	Play	2025-09-03 02:50:00	5
2	hana_1	Pulse	PLAY_SONG	2025/09/02 21:05:00	60
3	indra99	Langit Senja	Play	03/09/2025 00:03	180
4	linaaudio	City Lights	Play	03/09/2025 14:13	10
5	hana_1	Midnight Drive	start	2025/09/02 02:24:00	120
...	...	...	...	...	...
72	andi_music	City Lights	Play	2025-09-03 08:03:40	5

   Perlu diperhatikan bahwa pada kolom event_type terdapat berbagai jenis kategori dan tidak ditemukan adanya perbedaan pada kategori-kategori tersebut. Oleh karena itu, diputuskan bahwa seluruhnya akan dijadikan satu kategori, yaitu play.

3. Dengan menggunakan data yang sama, tampak bahwa terdapat ketidakkonsistenan penulisan data pada kolom listen_timestamp sehingga dibuat kembali dengan format tahun-bulan-tanggal jam:menit:detik.

4. Sebagai langkah terakhir, dibuat data baru bernama clean_logs untuk merangkum hasil seluruh proses pembersihan data yang telah dilakukan sebelumnya. Data baru tersebut juga menggabungkan ketiga file data yang terdapat dalam *database* ini.

5 Perbaikan ERD

Struktur basis data awal belum memenuhi prinsip normalisasi karena relasi antar tabel belum jelas dan masih menggunakan atribut berbasis teks.

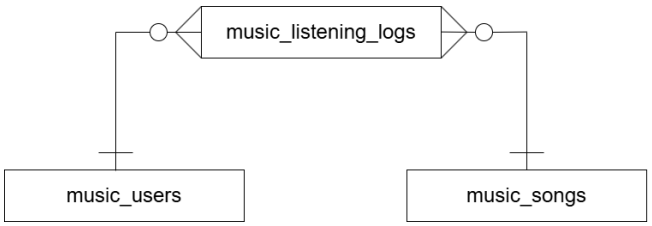
Sebagai perbaikan, dibangun model relasi sebagai berikut

1. Tabel users menyimpan data pengguna
2. Tabel songs menyimpan data lagu
3. Tabel listening_logs menjadi tabel penghubung yang mencatat aktivitas pemutaran

Relasi yang terbentuk

1. Satu pengguna dapat memiliki banyak aktivitas (*one-to-many*)
2. Satu lagu dapat diputar oleh banyak pengguna (*one-to-many*)

Dengan demikian, struktur data menjadi lebih terorganisir dan mendukung analisis yang lebih akurat. Oleh karena itu, berikut dapat dibentuk digaram E-R untuk menjelaskan dengan detail mengenai relasi antar tabel



Gambar 1: Diagram E-R

6 Hasil Pengolahan Data

Setelah tahap pembersihan selesai, data siap untuk diolah menggunakan MySQL guna menjawab kelima pertanyaan yang terdapat pada petunjuk laporan. Setiap pertanyaan akan dijawab dengan menyertakan bentuk aljabar relasional beserta hasil keluaran datanya.

1. Genre musik apa yang paling sering diputar setelah proses standardisasi?
   Berikut adalah penulisan aljabar relasional:

   $$\sigma_{genre_text,COUNT(*)}(clean_logs)$$

   Keluaran yang dihasilkan menunjukkan bahwa genre pop mendominasi daftar putar:

   Tabel 4: Tabel Total Pemutaran Berdasarkan *genre_text*

genre_text	**total_play**
pop	39
rock	12
electronic	12
acoustic	9

2. Siapa artis dengan jumlah pemutaran terbanyak?
   Berikut adalah penulisan aljabar relasionalnya:

   $$\sigma_{artist_name_text,COUNT(*)}(clean_logs)$$

   Berdasarkan keluaran tersebut, Nova merupakan artis yang lagunya paling sering diputar oleh pengguna:

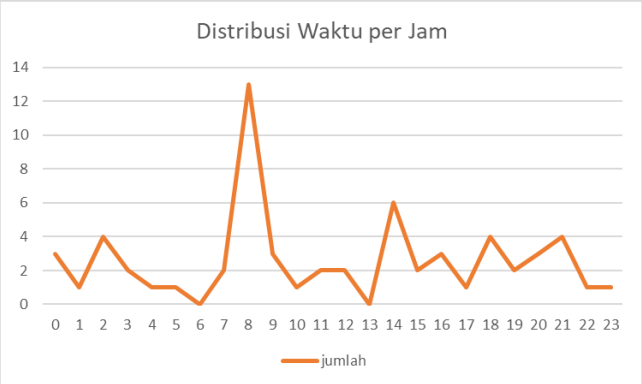
   Tabel 5: Tabel Total Pemutaran Berdasarkan *artist_text*

artist_text	**total_play**
Nova	18
Adera	13
Neon	12
...	...
Arsy	3

3. Bagaimana distribusi aktivitas mendengarkan berdasarkan waktu?
   Berikut adalah penulisan aljabar relasionalnya:

   $$\sigma_{listen_timestamp,COUNT(*)}(clean_logs)$$

Hasil dari kueri ini divisualisasikan dalam bentuk Grafik Garis Distribusi Waktu per Jam. Berdasarkan grafik tersebut, terlihat bahwa aktivitas mendengarkan musik berfluktuasi secara signifikan sepanjang hari.



Gambar 2: Grafik Garis Distribusi Waktu

Puncak aktivitas tertinggi terjadi pada pukul 08:00 pagi dengan total 13 pemutaran. Selain itu, terdapat beberapa lonjakan aktivitas sekunder yang lebih kecil, yaitu pada pukul 14:00 (6 pemutaran), serta pada pukul 02:00, 18:00, dan 21:00 (masing-masing 4 pemutaran). Sebaliknya, intensitas mendengarkan paling rendah (menyentuh angka nol) terjadi pada pukul 06:00 pagi dan 13:00 siang.

4. Pengguna mana yang paling aktif mendengarkan musik?
   Berikut adalah penulisan aljabar relasionalnya:

$$\sigma_{username, COUNT(*)}(clean_logs)$$

Berikut adalah daftar pengguna dengan frekuensi aktivitas pemutaran tertinggi:

Tabel 6: Tabel Total Pemutaran Berdasarkan *username*

artist_text	**total_play**
andi_music	13
hana_l	7
linaaudio	6
...	...
oki_listen	2

Dari data di atas, dapat disimpulkan bahwa pengguna dengan nama akun "andi_music" merupakan pendengar yang paling aktif dibandingkan dengan pengguna lainnya.

5. Apakah terdapat aktivitas pemutaran yang berpotensi tidak wajar?
   Berikut adalah penulisan aljabar relasionalnya:

$$\sigma_{COUNT(*)}(\sigma_{duration_seconds \leq 5 \vee duration_seconds \geq 3600}(clean_logs))$$

Berdasarkan hasil eksekusi kueri di atas, ditemukan bahwa terdapat sebanyak 20 aktivitas pemutaran yang dikategorikan tidak wajar atau merupakan anomali (misalnya durasi mendengarkan yang terlalu singkat di bawah 5 detik, atau terlalu lama melebihi batas 3600 detik).

Tabel 7: Log Aktivitas Mendengarkan Lagu

log_id	user_name	song_title	event_type	listen_timestamp	duration_seconds
72	andi_music	City Lights	play	2025-09-03 08:03:40	5
71	andi_music	City Lights	play	2025-09-03 08:03:20	5
70	andi_music	City Lights	play	2025-09-03 08:03:00	5
69	andi_music	City Lights	play	2025-09-03 08:02:40	5
68	andi_music	City Lights	play	2025-09-03 08:02:20	5
...	...	...	...	...	...
37	linaaudio	City Lights	play	2025-09-04 07:36:00	5

7 Data Sintesis

Pada data awal, terdapat beberapa variasi kategori pada atribut *event_type*, seperti 'Play', 'play', 'listen', 'start', dan 'PLAY_SONG'. Meskipun penulisannya berbeda, seluruh kategori tersebut memiliki makna yang sama, yaitu aktivitas memutar musik. Oleh karena itu, kategori-kategori tersebut diseragamkan ke dalam satu label, yaitu 'play', untuk menjaga konsistensi data.

Selain itu, dilakukan penambahan data sintesis berupa *log_id* dari 73 hingga 100. Data tambahan ini mencakup variasi kategori baru pada atribut *event_type*, yaitu 'like' dan 'save', guna memperkaya jenis interaksi pengguna dalam dataset.

Berikut adalah data sintesis yang ditambahkan

Tabel 8: Data Sintetis Tambahan

log_id	user_name	song_title	event_type	listen_timestamp	duration_seconds
73	andi_music	City Lights	like	2025-09-04 08:15:00	0
74	kiki_song	Langit Senja	SAVE	2025/09/04 08:20:00	0
75	hana_l	Pulse	Liked	04/09/2025 08:30	0
76	indra99	Broken Roads	Liked	2025-04 09:10	0
77	dewii	Silent Echo	Like	2025-09-04 09:25:00	0
...	...	...	...	...	...
100	andi_music	Langit Senja	Saved	2025-09-04 23:00:00	0

Data sintesis ini memiliki jenis-jenis kategori seperti, 'like', 'SAVE', 'liked', dan 'saved. Setelah dilakukan proses normalisasi event kategori tersebut dikategorikan menjadi 'like' dan 'save'. Namun perlu diperhatikan bahwa penambahan data sintesis ini tidak mempengaruhi jawaban pada nomor 1-5.

8 Kesimpulan

Proses pembersihan dan transformasi data berhasil meningkatkan kualitas data sehingga dapat digunakan untuk analisis lebih lanjut. Standardisasi atribut dan perbaikan relasi memungkinkan identifikasi pola perilaku pengguna serta popularitas musik secara lebih akurat.

Analisis menunjukkan bahwa terdapat preferensi genre tertentu, artis yang dominan, serta pola waktu dalam aktivitas mendengarkan. Selain itu, ditemukan pula beberapa anomali data yang perlu diperhatikan dalam pengelolaan sistem ke depan.

Berikut adalah lampiran repository GitHub: https://github.com/brydrw27/RekayasaData-KelompokB-25-26.git